

多模态 agent 网页自动化开题报告

姓名	学号	院系	专业
何翌宁	23336085	计算机学院	计算机科学与技术
林璐	23336138	计算机学院	计算机科学与技术
林翠敏	23336135	计算机学院	系统结构
选题	题目 7：网页多模态 Agent（界面理解+自动操作）		

一、选题研究的目的、意义及国内外研究现状

1.1 任务定义与应用背景

（1）任务定义：

本课题旨在构建一个能够理解网页界面并执行自然语言指令的网页多模态智能 Agent。用户输入类似“点击登录按钮”、“在搜索框中输入天气并查询”等指令，Agent 自动完成浏览器操作（点击、输入、滚动等），并返回执行结果。系统需支持多轮交互，具备对动态网页的适应能力。

核心目标为将“自然语言任务”转化为“可执行的操作序列”，并在真实网页环境中完成任务。

（2）应用背景：

随着互联网服务复杂度不断提升，用户在网页中的操作成本显著增加，该类 Agent 具有广泛应用价值：

- 自动化测试：替代传统脚本，用自然语言描述测试用例，降低维护成本。
- 个人助手：帮助视障人士或非技术用户完成网页任务（表单填写、信息检索）。
- 机器人流程自动化：与 RPA 结合，实现跨网站的数据采集与业务处理。
- 多模态智能体评测：为通用 AI Agent 提供可交互的真实环境基准。

1.2 国内外研究现状与趋势

(对应文献见“六、参考文献”部分。)

近年来，随着多模态大模型和智能体（Agent）技术的快速发展，面向网页环境的自动化操作问题逐渐成为人工智能领域的研究热点。网页多模态 Agent 旨在基于网页界面信息与自然语言指令，实现对网页内容的理解与自动交互，其本质涉及视觉理解、语言理解与序列决策等多个关键问题。当前，国内外相关研究主要可以分为以下几类：基于结构信息的方法、基于视觉感知的方法以及多模态融合方法。

早期的网页自动化研究主要依赖网页的结构信息（如 HTML DOM 树）进行建模。这类方法通过解析网页元素的标签、属性及层级关系，将网页任务转化为结构化决策问题。例如，OpenAI 提出的 WebGPT 模型[1]通过调用浏览器接口访问网页，并结合语言模型进行信息检索与决策，实现了基于网页内容的问答任务。类似地，MiniWoB++[2]等工作构建了标准化的网页交互环境，将网页操作抽象为强化学习问题，使得模型能够通过试错学习点击、输入等基本操作。然而，这类方法高度依赖网页的结构信息，在面对不同网站布局差异时泛化能力较弱，难以适应真实复杂网页环境。

随着计算机视觉技术的发展，研究者开始尝试直接基于网页截图进行界面理解，从而摆脱对 DOM 结构的依赖。近年来，视觉语言模型（Vision-Language Model, VLM）的兴起为该方向提供了重要支撑。例如，SeeAct[3]利用 GPT-4V 等视觉大模型直接对网页截图进行解析，通过识别界面中的按钮、文本及布局信息，实现端到端的网页操作决策。该方法更接近人类操作网页的方式，具有更强的跨网站泛化能力。此外，以 LLaVA[4]为代表的多模态模型通过对图像与文本的联合建模，使模型具备较强的视觉语义理解能力，为网页界面理解任务提供了通用基础。然而，纯视觉方法在处理复杂界面时仍面临元素识别不准确、文本信息提取困难等问题。

在此基础上，研究逐渐向多模态融合方向发展，即同时利用网页截图、DOM 结构以及自然语言指令进行联合建模。Mind2Web[5]构建了大规模真实网页任务数据集，并提出基于多模态输入的网页 Agent 框架，使模型能够在复杂网页环境中执行多步任务操作。WebArena[6]进一步提供了接近真实互联网环境的评测平台，用于系统性评估 Agent 在网页任务中的表现。这类方法通过融合视觉信息与结构信息，在一定程度上兼顾了表达能力与稳定性，代表了当前网页 Agent 研究的主流方向。

在决策与推理机制方面，ReAct 框架[7]提出将“推理（Reasoning）”与“行动（Acting）”相结合，使模型在执行任务过程中能够动态生成中间推理步骤并

据此选择操作动作。这一思想被广泛应用于各类 Agent 系统中，有效提升了复杂任务的可解释性与成功率。同时，AutoGPT 等开源项目进一步探索了基于大模型的自主任务执行能力，使 Agent 能够在较少人工干预的情况下完成多步骤任务，推动了网页自动化向更高智能水平发展。

尽管当前研究已取得显著进展，但网页多模态 Agent 仍面临诸多挑战。首先，网页界面元素种类繁多且布局复杂，视觉模型在精确定位可交互元素方面仍存在困难；其次，多步骤任务中误差容易累积，一旦某一步操作失败，可能导致整个任务无法完成；再次，不同网站之间在设计风格和交互逻辑上的差异较大，模型的泛化能力仍有待提升。此外，真实网页环境中的动态加载、异步交互等机制，也增加了任务执行的复杂性。

从发展趋势来看，网页多模态 Agent 正朝着以下几个方向演进：一是多模态深度融合，即结合视觉、文本与结构信息，提高界面理解的准确性；二是更强的规划与推理能力，通过引入长链推理和记忆机制提升复杂任务执行能力；三是标准化评测体系的完善，如 WebArena 等环境的推广将促进不同方法之间的公平比较；四是从研究走向实际应用，逐步融入智能浏览器助手与自动化办公系统中，推动人工智能在真实场景中的落地应用。

综上所述，网页多模态 Agent 作为多模态大模型与智能体技术的重要交叉方向，正处于快速发展阶段。现有研究在界面理解与任务执行方面已取得初步成果，但在鲁棒性、泛化能力及复杂任务处理方面仍存在提升空间。因此，在现有方法基础上设计轻量化、可实现的网页 Agent 系统，并对其性能进行实验验证，具有重要的研究意义与应用价值。

二、选题研究的计划进度及可行性论述

2.1 计划进度

时间阶段	工作内容
第 9-10 周	完成开题报告、架构设计、环境搭建（Playwright + VLM 部署）
第 11-12 周	开发 LLM 任务规划器；打通“VLM 看图解析 -> LLM 逻辑规划 -> 执行器物理操作”的自动闭环。
第 13-15 周	将 Agent 容器化部署至阿里云；在 GitHub、豆瓣等 3 个真实网站上完成 90 轮线上测试。
第 16-17 周	分析失败案例（感知/规划/执行）；准备最终报告、Demo 视频、代码仓库清理与文档撰写。

2.2 可行性论述

技术可行性：所有组件均为开源模型（Qwen2.5-VL 7B、Playwright 等），可在单张 RTX 3090/4090 上运行推理。

数据可行性：无需标注数据，使用已有网站（如 GitHub、豆瓣、中国天气网）交互日志自建评测任务集（每网站 ≥ 3 任务 $\times 10$ 轮）。

团队能力：成员掌握主流大模型（LLM/VLM）的本地部署、Prompt 工程与 API 调用；成员具备基于 Playwright 的自动化环境搭建与反爬虫绕过经验。团队具备从系统集成到定量评测的全栈开发能力，有能力胜任本课题研究。

资源保障：项目依托阿里云服务，保障单张 24GB 及以上显存 2 的计算资源，可以覆盖 7B 级别大模型的本地推理需求。

三、系统方案设计

3.1 总体架构

系统总体架构将分为 5 层，分别为用户接口层、决策层、感知层、执行层和判断层。其中用户接口层包括用户指令，决策层包括 LLM 以及 React 处理状态，感知层包括 VLM 处理页面状态、执行层包括 Playwright 处理浏览器具体操作、判断层包括判断当前是否到达结束状态。

以下为架构图：



3.2 模型选择

1. VLM

本项目选用轻量级视觉语言模型（如 CLIP 或 BLIP）对网页截图进行编码，将视觉信息转化为结构化表示，以支持后续决策模块的输入。同时结合 DOM 信息增强定位精度，提高界面理解的稳定性。

2. LLM

本项目采用基于 ReAct（Reasoning + Acting）框架的大语言模型作为决策核心，使模型能够在“推理-执行”交替过程中逐步生成操作序列。该方法相比一次性生成完整序列，能够更好适应网页环境的动态变化。其中本地模型选用 Qwen。

3. Playwright

本项目在执行层面，系统通过浏览器自动化工具（如 Playwright）完成具体操作，包括点击、输入与滚动等。该工具能够精确控制网页元素，并提供稳定的执行环境。

3.3 评测指标

本系统通过多指标综合评估方法，从整体成功率、步骤级准确性及序列一致性等多个维度对 Agent 性能进行分析，并结合错误类型分类，全面评估系统在真实网

页环境中的表现。

- **任务成功率**
用于衡量系统是否能够完整完成用户指定任务，是评价系统整体性能的核心指标。
任务成功率=成功任务数 / 总任务数
- **步骤准确率**
衡量每一步操作是否正确，用于分析模型在细粒度决策上的表现。
步骤准确率 = 正确动作数 / 总动作数
- **错误类型分析**
为深入分析系统性能，将失败案例分类，从而定位系统瓶颈并指导优化。
将错误分类为: 感知错误 (VLM)、规划错误 (LLM) 和执行错误 (Playwright)

四、实验设想

4.1 网站与任务设计

为全面评估网页多模态 Agent 的感知、推理与操作能力，本研究选取 3 个具有不同 UI 复杂度和交互逻辑的真实网站，构建具备难度梯度的测试任务集。每个网站设计 3 个典型场景，涵盖简单输入到复杂的多步检索与信息抽取（共计 9 个场景，每个场景进行 10 轮独立测试，总计 90 次测试）。

为开源社区 GitHub 设计基础搜索、跨页搜索和条件过滤任务；为信息聚合型网页豆瓣（DouBan）设计电影搜索、影评抓取和复杂翻页任务；为数据查询型网页中国天气网设计城市查询、多日趋势和气象指数提取等任务。

网站	场景示例	输入指令
GitHub	搜索仓库	“在搜索框中输入 ‘Qwen-VL’ ， 然后点击第一个结果”
中国天气网	查询城市天气	“在输入框中输入 ‘广州’ ， 点击 查询，读出最高温度”
豆瓣	搜索指定电影	“在搜索框输入 ‘流浪地球’ ， 按 下回车键确定键搜索，返回电影简

		介”
--	--	----

4.2 数据收集与标注

为保证评测过程的自动化与结果的可追溯性, 实验采用以下日志追踪与归因机制:

- **全链路状态快照**

系统将自动记录每一个交互轮次的完整状态向量, 包括输入输出环境 (用户指令、当前页面截图), 模型输出 (VLM 输出的自然语言推理过程以格式化动作指令) 与执行反馈 (Playwright 执行动作后的状态码及页面变化)。

- **失败归因**

对于没有成功执行的任务, 人工介入并根据模型交互日志进行分类诊断:
感知失败 (VLM 未能正确识别截图关键元素), 单步动作准确率 (计算生成的 JSON 指令与标准人类操作的最优路径的匹配度), 平均交互轮次 (轮次越少, 规划越优)。

4.3 预期结果

- **预期基准表现:** 基于现有文献 (如 WebVoyager, Mind2Web), 结合本方案的 VLM-LLM 融合架构, 预期在 “低/中等难度” 任务中, 平均 TSR 可达到 60% 以上。

架构有效性验证 (消融实验): 将构建两种对照基线:

- **Baseline A (纯文本驱动):** 仅输入精简指令, 剔除视觉截图。预期在遇到纯图
标按钮时定位失败率显著升高。
- **Proposed Method (多模态视觉融合):** 加入视觉截图, 预期其单步准确率和最
终 TSR 将显著优于 Baseline A。

五、算力预算与资源支持

本项目为网页多模态 Agent 系统，核心由视觉理解模块（VLM）、任务规划模块（LLM）及浏览器执行模块（playwright）组成。整体计算开销主要集中在模型推理阶段，对训练需求较低，因此算力需求以推理资源为主。

预计所需硬件配置如下：

- GPU：1 × 24GB 显存（如 RTX 3090 / A10）
- CPU：4 – 8 核（用于浏览器自动化与任务调度）
- 内存：16GB – 32GB
- 存储：≥50GB（用于模型与实验数据存储）

六、参考文献

- [1] Nakano R, Hilton J, Balaji S, et al. WebGPT: Browser-assisted question-answering with human feedback. arXiv:2112.09332v3, 2022
- [2] Shi T, Karpathy A, Fan L, et al. Reinforcement Learning on Web Interfaces Using Workflow-guided Exploration. arXiv:1802.08802v1, 2018
- [3] Henry S, Townsend C. A classifying groupoid for compact Hausdorff locales. arXiv:2310.07785v1, 2023
- [4] Liu H, Li C, Wu Q, et al. Visual Instruction Tuning. arXiv:2304.08485v2, 2023
- [5] Deng X, Gu Y, Zheng B, et al. Mind2Web: Towards a Generalist Agent for the Web. arXiv:2306.06070v3, 2023
- [6] Zhou S, Xu F, Zhu H, et al. WebArena: A Realistic Web Environment for Building Autonomous Agents. arXiv:2307.13854v4, 2024
- [7] Yao S, Zhao J, Yu D, et al. ReAct: Synergizing Reasoning and Acting in Language Models. arXiv:2210.03629v3, 2023

备注：本报告对应的代码仓库、环境配置（requirements.txt）及最终演示视频将于期末验收时一并提交。